
Redes Neuronales Artificiales

Tarea 2: minisom

Jairo Isaac Muñoz López
2020170203

Universidad
Tecnológica
de la Mixteca

Av. Modesto Seara Vázquez
Huajuapán de León, Oaxaca, México.

Índice general

0.1. Introducción	4
0.2. Bibliotecas	4
0.3. Preparación de los datos	4
0.4. Entrenamiento del SOM	4
0.5. Visualización de los resultados	5
0.6. Algunos resultados obtenidos	7
0.7. Conclusión	14

0.1 Introducción

Para esta tarea se implementará un mapa autoorganizado (SOM) utilizando la biblioteca `minisom` en Python. El SOM es una técnica de aprendizaje no supervisado que se utiliza para visualizar y analizar datos de alta dimensión. El objetivo es entrenar el SOM con un conjunto de datos y visualizar los resultados para comprender cómo el mapa organiza la información. Los datos que se pretenden analizar son una recopilación de registros de varias mediciones utilizadas en el diagnóstico de cáncer de mama. Y son obtenidos de `load_breast_cancer` de `sklearn.datasets`.

0.2 Bibliotecas

Se utilizaron las siguientes bibliotecas:

- `sklearn` para cargar el conjunto de datos de cáncer de mama, algunas métricas como el `adjusted_rand_score` y para la normalización de los datos con `MinMaxScaler`. También se importó `KMeans` para comparar los resultados del SOM con un método de clustering tradicional.
- `minisom` para implementar y entrenar el mapa autoorganizado (SOM).
- `matplotlib` para visualizar los resultados del SOM.
- `seaborn` para mejorar la estética de las visualizaciones.
- `numpy` para manejar los datos y realizar operaciones matemáticas.

0.3 Preparación de los datos

Se cargó el conjunto de datos de cáncer de mama utilizando `load_breast_cancer` de `sklearn.datasets`. Este conjunto de datos contiene características extraídas de imágenes de células mamarias, y se utiliza comúnmente para tareas de clasificación. Una vez cargados los datos, se normalizaron utilizando `MinMaxScaler` para escalar las características a un rango entre 0 y 1. Esto es importante para asegurar que todas las características tengan la misma escala y evitar que algunas dominen el entrenamiento del SOM.

0.4 Entrenamiento del SOM

Se creó un mapa autoorganizado (SOM) utilizando la clase `MiniSom` de la biblioteca `minisom`. Se especificaron las dimensiones del mapa (por ejemplo, 10x10) y el número de características en los datos. Luego, inicializamos los pesos del SOM utilizando el método `pca_weights_init` y se entrenó el SOM utilizando el método `train_batch`. Durante el entrenamiento, el SOM ajusta sus pesos para organizar los datos de manera que las muestras similares se agrupen juntas en el mapa. Cabe señalar que se realizaron variaciones en los parámetros del entrenamiento, como la tasa de aprendizaje y

el valor para `sigma`, para observar cómo afectan la organización del mapa. Además, se experimentó con diferentes tamaños de mapa para encontrar la configuración que mejor se adapte a los datos. En el caso de la función de vecindad, se utilizó la función `mexican_hat` para definir cómo se actualizan los pesos de las neuronas vecinas durante el entrenamiento. Para el parámetro `input_len`, se especificó el número de características en los datos, que es necesario para que el SOM pueda procesar correctamente las entradas. Utilizamos `KMeans` para comparar los resultados del SOM con un méto-

do de clustering tradicional. Esto nos permitió evaluar la efectividad del SOM en la organización de los datos y su capacidad para identificar patrones y grupos en el conjunto de datos de cáncer de mama. Para obtener las etiquetas de los clusters formados por el SOM, se asignó a cada muestra la etiqueta del nodo ganador correspondiente. Luego, se compararon estas etiquetas con las etiquetas reales del conjunto de datos utilizando la métrica `adjusted_rand_score` para evaluar la calidad del clustering realizado por el SOM. Para el cálculo del ari se usó la función `adjusted_rand_score` de

`sklearn.metrics`, que compara las etiquetas de los clusters obtenidos por el SOM con las etiquetas reales del conjunto de datos. El ARI es una medida de similitud entre dos agrupamientos, donde un valor de 1 indica una coincidencia perfecta, un valor de 0 indica una coincidencia aleatoria. Y se le pasaron las etiquetas obtenidas del SOM y las etiquetas reales del conjunto de datos para calcularlo.

0.5 Visualización de los resultados


Se utilizaron visualizaciones para interpretar los resultados del SOM. Se creó un mapa de calor para mostrar la distribución de las muestras en el mapa, donde cada celda representa un nodo del SOM y el color indica la cantidad de muestras asignadas a ese nodo. Además, se visualizó la distancia entre los nodos utilizando un mapa de distancias, lo que permite identificar áreas del mapa donde las muestras están más agrupadas o dispersas. También se utilizaron gráficos de dispersión para mostrar cómo se agrupan las muestras en el espacio de características y cómo se relacionan con las etiquetas reales del conjunto de datos. Estas visualizaciones ayudan a comprender cómo el SOM organiza los datos y a identificar patrones o grupos en el conjunto de datos de cáncer de mama. El mapa está generado por `plt.imshow(u_matrix, cmap='winter')`, donde `u_matrix` es la matriz de distancias entre los nodos del SOM. El mapa de calor se muestra utilizando la función `plt.imshow` con el mapa de colores `'winter'`, que proporciona una representación visual de las distancias entre los nodos del SOM. Las áreas con colores más oscuros indican nodos que están más cercanos entre sí, mientras que las áreas con colores más claros indican nodos que están más alejados. Esto permite identificar regiones del mapa donde las muestras están más agrupadas o dispersas, lo que puede ser útil para interpretar los resultados del SOM y comprender la estructura de los datos. Posteriormente, se superponen los pacientes en el mapa de calor utilizando un gráfico de dispersión, donde cada punto representa un paciente y su posición corresponde al nodo ganador del SOM. Los puntos se colorean según su clase real (maligno o benigno), lo que permite visualizar cómo se agrupan

los pacientes en el mapa y cómo se relacionan con las etiquetas reales del conjunto de datos. Esta visualización ayuda a interpretar los resultados del SOM y a identificar patrones o grupos en el conjunto de datos de cáncer de mama. Veamos un ejemplo de cómo se implementa esto en código: Parámetros utilizados para el entrenamiento del

SOM:

- `map_size`: (15, 15) - Tamaño del mapa SOM
- `sigma`: 0.5
- `learning_rate`: 0.05
- `neighborhood_function`: 'mexican_hat'
- `input_len`: número de características en los datos (en este caso, 30)
- `random_seed`: 42

El mapa obtenido para este caso es el siguiente:



En este mapa, cada celda representa un nodo del SOM, y el color indica la cantidad, entre más azul sea una zona del mapa, más muestras están asignadas a ese nodo. Los puntos rojos representan pacientes malignos, mientras que los puntos verdes representan pacientes benignos. Podemos observar cómo se agrupan los pacientes en el mapa y cómo se relacionan con las etiquetas reales del conjunto de datos de cáncer de mama. Las zonas con un tono casi verde representan nodos que están más alejados del resto, mientras que las zonas con un tono casi azul representan nodos que están más cercanos entre sí. Esto nos permite identificar regiones del mapa donde las muestras están más agrupadas o dispersas, lo que puede ser útil para interpretar los resultados del

SOM y comprender la estructura de los datos. En principio, se esperaría que las zonas color verde actúen como fronteras entre los grupos de pacientes malignos y benignos, mientras que las zonas color azul representen áreas donde ambos tipos de pacientes están más mezclados. Sin embargo, la interpretación exacta del mapa dependerá de la distribución de los datos y de cómo el SOM haya organizado las muestras en el espacio del mapa.

0.6 Algunos resultados obtenidos

variaremos los parámetros del entrenamiento para observar cómo afectan la organización del mapa. A continuación, se muestran algunos resultados obtenidos con diferentes configuraciones de parámetros.




Figura 1: Tamaño del mapa: 15x15, Sigma: 0.5, Learning rate: 0.05




Figura 2: Tamaño del mapa: 15x15, Sigma: 0.8, Learning rate: 0.3




Figura 3: Tamaño del mapa: 15x15, Sigma: 1.0, Learning rate: 0.001




Figura 4: Tamaño del mapa: 19x19, Sigma: 1.0, Learning rate: 0.001




Figura 5: Tamaño del mapa: 19x19, Sigma: 0.6, Learning rate: 0.1




Figura 6: Tamaño del mapa: 19x19, Sigma: 0.1, Learning rate: 1




Figura 7: Tamaño del mapa: 7x7, Sigma: 0.1, Learning rate: 1




Figura 8: Tamaño del mapa: 7x7, Sigma: 0.05, Learning rate: 0.01




Figura 9: Tamaño del mapa: 7x7, Sigma: 0.4, Learning rate: 0.2




Figura 10: Tamaño del mapa: 29x29, Sigma: 0.4, Learning rate: 0.2




Figura 11: Tamaño del mapa: 29x29, Sigma: 1, Learning rate: 0.01




Figura 12: Tamaño del mapa: 29x29, Sigma: 1, Learning rate: 0.01

veamos ahora un mapa no cuadrado, con un tamaño de 15x38, sigma de 0.3 y learning rate de 0.5:




Figura 13: Tamaño del mapa: 15x38, Sigma: 0.3, Learning rate: 0.5

0.7 Conclusión

En esta tarea se implementó un mapa autoorganizado (SOM) utilizando la biblioteca `minisom` en Python para analizar un conjunto de datos de cáncer de mama. Se prepararon los datos, se entrenó el SOM y se visualizaron los resultados para comprender cómo el mapa organiza la información. El SOM permitió identificar patrones y grupos en el conjunto de datos, y se compararon los resultados con un método de clustering tradicional utilizando `KMeans`. La visualización del mapa de calor y la superposición de los pacientes en el mapa ayudaron a interpretar los resultados y a comprender la estructura de los datos. En general, el SOM demostró ser una herramienta útil para analizar y visualizar datos de alta dimensión, como el conjunto de datos de cáncer de mama. El ARI más alto obtenido fue de 0.77 con un mapa de tamaño 29x29, sigma de 0.05 y learning rate de 0.01, lo que indica una buena coincidencia entre los clusters formados por el SOM y las etiquetas reales del conjunto de datos. Sin embargo, es importante tener en cuenta que la interpretación de los resultados del SOM puede ser subjetiva y dependerá de la distribución de los datos y de cómo el SOM haya organizado las muestras en el espacio del mapa. vease la Figura 8.